



CONCEITOS BÁSICOS SOBRE PLN

PROCESSAMENTO DE LINGUAGEM NATURAL

CST em Desenvolvimento de Software Multiplataforma



PROF. Me. TIAGO A. SILVA



CONCEITOS FUNDAMENTAIS DE PLN

CONCEITO	O QUE SIGNIFICA
<i>Tokenização</i>	Dividir texto em unidades menores
<i>Lematização</i>	Reduzir palavras à forma base
<i>POS Tagging</i>	Classificar palavras gramaticalmente
<i>Parsing</i>	Analisar estrutura sintática
<i>NER</i>	Identificar entidades
<i>Stop Words</i>	Remover palavras irrelevantes
<i>Embeddings</i>	Representação vetorial semântica

UM EXEMPLO PARA COMEÇAR

```
1 import spacy
2
3 nlp = spacy.load("pt_core_news_sm")
4 texto = "O professor Tiago explicou PLN usando spaCy na Fatec."
5
6 doc = nlp(texto)
7
8 for token in doc:
9     print(
10         f"Texto: {token.text:10} | "
11         f"Lemma: {token.lemma_:10} | "
12         f"POS: {token.pos_:6} | "
13         f"Stop: {token.is_stop}"
14     )
15
16 print("\nEntidades:")
17 for ent in doc.ents:
18     print(ent.text, ent.label_)
```

SAÍDA DO CÓDIGO EXEMPLO

Texto: O	Lemma: o	POS: DET	Stop: True
Texto: professor	Lemma: professor	POS: NOUN	Stop: False
Texto: Tiago	Lemma: Tiago	POS: PROPN	Stop: False
Texto: explicou	Lemma: explicar	POS: VERB	Stop: False
Texto: PLN	Lemma: pLN	POS: SCONJ	Stop: False
Texto: usando	Lemma: usar	POS: VERB	Stop: False
Texto: spaCy	Lemma: spaCy	POS: NOUN	Stop: False
Texto: na	Lemma: em o	POS: ADP	Stop: True
Texto: Fatec	Lemma: Fatec	POS: NOUN	Stop: False
Texto: .	Lemma: .	POS: PUNCT	Stop: False

Entidades:

Tiago PER

Fatec ORG

POR QUE VAMOS USAR A spaCy

- **spaCy** é excelente para:
 - Demonstrar conceitos teóricos de PLN com prática imediata
 - Mostrar pipeline de processamento real
 - Conectar teoria linguística com aplicações
 - Preparar **base para transformers** (ex: BERT)



PIPELINE DO OBJETO DA spaCy

- O objeto **doc** passa por um pipeline que pode conter:
 - 1) Tokenizer
 - 2) Tagger (POS tagging)
 - 3) Parser (dependência sintática)
 - 4) NER (Reconhecimento de Entidades Nomeadas)
 - 5) Lemmatizer



```
9 # Imprimindo os nomes dos componentes do pipeline
10 print(nlp.pipe_names)
```

TOKENIZAÇÃO

- É o primeiro passo, consiste em dividir uma frase em unidades menores, chamadas. Os **tokens** são palavras ou pontuações, mas também podem ser sub-palavras (comum em modelos modernos).
 - Exemplo: "O gato correu." → ["O", "gato", "correu", "."]



```
12 # Imprimindo os tokens do texto
13 for token in doc:
14     print(token.text)
```



```
O
professor
Tiago
está
ensinando
PLN
na
Fatec
Jahu
.
```

LEMMA (LEMATIZAÇÃO)

- A forma canônica ou a base de cada palavra

```
16 # Imprimindo os lemas dos tokens
17 for token in doc:
18     print(token.text, "->", token.lemma_)
```



```
O -> o
professor -> professor
Tiago -> Tiago
está -> estar
ensinando -> ensinar
PLN -> PLN
na -> em o
Fatec -> Fatec
Jahu -> Jahu
. -> .
```


POS TAGGING (CLASSE GRAMATICAL)

- **Part-of-Speech (POS)** é o processo de rotular cada token de uma frase com sua classe gramatical (existem muitas).
- Existem diferentes conjuntos de etiquetas (tagsets):
 - Classes gramaticais da linguística tradicional
 - Tagset universal (Universal Dependencies – usado em pesquisas modernas)
 - Tagset Penn Treebank (muito usado em inglês e em bibliotecas clássicas)



```
20 # Imprimindo os tokens e suas classes gramaticais
21 for token in doc:
22     print(token.text, token.pos_)
```

POS TAGGING (CLASSE GRAMATICAL)

TAG	NOME	EXEMPLO
ADJ	Adjetivo	bonito
ADP	Adposição (preposição/pós)	de
ADV	Advérbio	rapidamente
AUX	Verbo auxiliar	ter, ser
CCONJ	Conjunção coordenativa	e
DET	Determinante	o, um
INTJ	Interjeição	ah
NOUN	Substantivo comum	casa
NUM	Numeral	dois
PART	Partícula	não
PRON	Pronome	ele
PROPN	Substantivo próprio	Brasil
PUNCT	Pontuação	. , !
SCONJ	Conjunção subordinativa	porque
SYM	Símbolo	%
VERB	Verbo principal	correr
X	Desconhecido/outro	token estranho

STOP WORDS (PALAVRAS DE PARADA)

- São palavras que **ocorrem com muita frequência** mas carregam **pouco significado semântico** para certas análises (como "de", "a", "o", "com"). Muitas vezes, elas são removidas para reduzir o ruído nos dados.



```
16 # Imprimindo os tokens e se são stop words
17 for token in doc:
18     print(token.text, token.is_stop)
```



```
O True
professor False
Tiago False
está True
ensinando False
PLN False
na True
Fatec False
Jahu False
. False
```

DEPENDÊNCIA SINTÁTICA (DEPENDENCY PARSING)

- Identifica relações gramaticais entre palavras:



```
20 # Imprimindo as dependências sintáticas dos tokens
21 for token in doc:
22     print(token.text, token.dep_, token.head.text)
```



```
0 det professor
professor nsubj ensinando
Tiago nsubj ensinando
está aux ensinando
ensinando ROOT ensinando
PLN obj ensinando
na case Fatec
Fatec obl ensinando
Jahu flat:name Fatec
. punct ensinando
```

NAMED ENTITY RECOGNITION (NER)

- **Reconhecimento de Entidades Nomeadas** identifica:
 - Pessoas
 - Organizações
 - Localizações
 - Datas
 - Valores monetários



```
26 # Imprimindo as entidades nomeadas do texto
27 for ent in doc.ents:
28     print(ent.text, ent.label_)
```

VETORES E SIMILARIDADE

- Alguns modelos do spaCy possuem **word embeddings**, que permitem medir similaridade semântica:
 - Sistemas de recomendação
 - Busca semântica
 - Agrupamento de textos



```
32  nlp = spacy.load("pt_core_news_lg")
33  doc1 = nlp("inteligência artificial")
34  doc2 = nlp("aprendizado de máquina")
35
36  print(doc1.similarity(doc2))
```

SENTENÇAS

- O spaCy também divide texto em sentenças:



```
40 # Imprimindo as sentenças do texto
41 doc = nlp("Eu gosto de IA. Ela transforma o mundo.")
42
43 for sent in doc.sents:
44     print(sent.text)
```

EXERCÍCIOS

Exercícios de fixação no Jupyter Notebook

EXERCÍCIO 1 – EXPLORANDO TOKENS

- Dado o texto:
 - *"A inteligência artificial está transformando a educação superior no Brasil."*
- Faça um programa que:
 - a) Mostre todos os tokens
 - b) Mostre apenas tokens que são palavras (ignore pontuação)
 - c) Conte o número total de tokens

EXERCÍCIO 2 – LEMATIZAÇÃO E NORMALIZAÇÃO

- Dado o texto:
 - *"Os alunos estavam estudando algoritmos e implementaram soluções eficientes."*
- Faça um programa que:
 - a) Mostre **token.text** e **token.lemma_**
 - b) Gere uma lista contendo apenas os lemas
 - c) Compare o texto original com o texto lematizado

EXERCÍCIO 3 – FILTRAGEM POR CLASSE GRAMATICAL

- Dado um texto qualquer a sua escolha, faça:
 - a) Extraia apenas os verbos
 - b) Extraia apenas os substantivos
 - c) Conte quantos verbos existem no texto
- Use **token.pos_**
- **Desafio extra:**
 - Mostrar verbo + seu sujeito usando dependência sintática



EXERCÍCIO 4 – STOPWORDS E ESTATÍSTICAS

- Dado um parágrafo maior:
 - Remova stopwords
 - Remova pontuação
 - Gere uma lista de palavras "limpas"
 - Mostre as 5 palavras mais frequentes
- Objetivo:
 - Introduzir pré-processamento para Machine Learning



EXERCÍCIO 5 – FREQUÊNCIA DE PALAVRAS

- Crie um programa que:
 - a) Conte a frequência de cada palavra
 - b) Ordene da mais frequente para a menos frequente
 - c) Ignore:
 - Stopwords
 - Pontuação
 - Palavras com menos de 3 letras



EXERCÍCIO 6 – ENTIDADES NOMEADAS (NER)

- Dado o texto faça:
 - *"A OpenAI foi fundada em 2015 e possui escritórios em São Francisco."*
 - a) Extraia todas as entidades
 - b) Mostre texto da entidade + tipo (**ent.label_**)
 - c) Conte quantas entidades de cada tipo existem
- Responda:
 - Como isso poderia ser usado em um sistema jurídico?
 - Ou em análise de notícias?

EXERCÍCIO 7 – MINI ANALISADOR DE NOTÍCIAS

- Busque uma noticia qualquer online e faça:
 - Extraia da notícia: Pessoas, organizações e Datas
 - Mostre um resumo estruturado: Pessoas Entradas, Organizações, Datas, etc.



EXERCÍCIO 8 – ANÁLISE SINTÁTICA

- Dado o texto:
 - *"O professor explicou aprendizado de máquina aos alunos."*
- Faça um programa que:
 - Identifique o verbo principal
 - Identifique o sujeito
 - Identifique o objeto
- Use:
 - `token.dep_` e `token.head`
- **Desafio:** Testar com frases mais complexas



EXERCÍCIO 9 – SIMILARIDADE SEMÂNTICA

- **Compare:**
 - "inteligência artificial"
 - "aprendizado de máquina"
 - "futebol"
 - "redes neurais"
 - Calcule similaridade entre cada par
 - Mostre quais são semanticamente mais próximas
- **Responda:**
 - O modelo pequeno (sm) é confiável para similaridade?



OBRIGADO!

- Encontre este **material on-line** em:
 - Slides: **Google Classroom**
- Em caso de **dúvidas**, entre em contato:
 - **Prof. Me. Tiago:** tiago.silva@cps.sp.gov.br

