



TF-IDF : TERM FREQUENCY - INVERSE DOCUMENT FREQUENCY

PROCESSAMENTO DE LINGUAGEM NATURAL
CST em Desenvolvimento de Software Multiplataforma



PROF. Me. TIAGO A. SILVA



O QUE É TF-IDF: “TERM FREQUENCY – INVERSE DOCUMENT FREQUENCY”?

- O **TF-IDF** (*Term Frequency – Inverse Document Frequency*) é uma técnica de estatística e processamento de linguagem natural (PLN) utilizada para **medir a importância de uma palavra em um documento** em relação a uma coleção de documentos (chamada de **corpus**).
- Amplamente utilizada em **sistemas de busca, mineração de textos e classificação de documentos**, pois ajuda a filtrar palavras comuns que não agregam valor semântico (como "de", "o", "que").

COMO TF-IDF FUNCIONA?

- O valor TF-IDF é o resultado da multiplicação de **duas métricas** principais:

1) Term Frequency (TF)

- Mede a frequência com que um termo aparece em um documento específico. A ideia é: **quanto mais uma palavra aparece, mais importante ela deve ser para aquele texto.**

$$TF(t, d) = \frac{\text{Número de vezes que o termo } t \text{ aparece no documento } d}{\text{Total de termos no documento } d}$$

COMO TF-IDF FUNCIONA?

- O valor TF-IDF é o **resultado da multiplicação** de **duas métricas** principais:

2) Inverse Document Frequency (*IDF*)

- **Mede o quão rara é uma palavra em todo o corpus.** Se uma palavra aparece em quase todos os documentos (como "computador" em um site de tecnologia), ela não é um bom diferencial.

$$IDF(t, D) = \log \left(\frac{\text{Total de documentos } N}{\text{Documentos contendo o termo } t} \right)$$

RESULTADO FINAL

- O valor **TF-IDF** aumenta proporcionalmente ao número de vezes que uma palavra aparece no documento, mas é compensado pela frequência da palavra no corpus.
 - Observação: leia “**TF-IDF**” como sendo uma única variável e não “*TF menos IDF*”.

$$TF - IDF = TF \times IDF$$



CALCULANDO UM EXEMPLO

Observando como a métrica é calculada

EXEMPLO: *CORPUS* COM 3 DOCUMENTOS

- Sendo os três documentos:
 - D_1 "O gato comeu o peixe."
 - D_2 "O gato dormiu no sofá."
 - D_3 "O cachorro correu no parque."
- Se calcularmos o **TF-IDF** para a palavra "**gato**":
 - No D_1 , o TF é alto (a palavra aparece).
 - No Corpus (os três documentos), o **IDF** será moderado (ela aparece em 2 de 3 documentos).
 - Já a palavra "**peixe**" terá um TF-IDF muito maior no D_1 , pois ela é exclusiva daquele contexto, tornando-se uma palavra-chave mais forte para identificar o conteúdo do primeiro documento.

ANALISANDO O EXEMPLO

- Primeiro, contamos o total de palavras em cada documento:
 - D_1 "O gato comeu o peixe." (5 palavras)
 - D_2 "O gato dormiu no sofá." (5 palavras)
 - D_3 "O cachorro correu no parque." (5 palavras)
- Agora vamos calcular a Term Frequency (TF)

$$TF(t, d) = \frac{\text{Número de vezes que o termo } t \text{ aparece no documento } d}{\text{Total de termos no documento } d}$$

CALCULANDO A PRIMEIRA MÉTRICA: TERM FREQUENCY (TF)

$$TF(t, d) = \frac{\text{Número de vezes que o termo } t \text{ aparece no documento } d}{\text{Total de termos no documento } d}$$

$$TF("gato", D_1) = \frac{1}{5} = \mathbf{0,2}$$

$$TF("gato", D_2) = \frac{1}{5} = \mathbf{0,2}$$

$$TF("gato", D_3) = \frac{0}{5} = \mathbf{0}$$



CALCULANDO A SEGUNDA MÉTRICA: INVERSE DOCUMENT FREQUENCY (*IDF*)

$$IDF(t, D) = \log \left(\frac{\text{Total de documentos } N}{\text{Documentos contendo o termo } t} \right)$$

$$IDF(t, D) = \log \left(\frac{N}{df} \right)$$

- Onde:

- $N = 3$ (número total de documentos)
- $df = 2$ (Número de documentos que contém a palavra **"gato"**: D_1 e D_2)

$$IDF("gato") = \log \left(\frac{3}{2} \right) = \log(1,5) \approx \mathbf{0,405}$$



CALCULANDO A SEGUNDA MÉTRICA: INVERSE DOCUMENT FREQUENCY (*IDF*)

$$IDF(t, D) = \log \left(\frac{\text{Total de documentos } N}{\text{Documentos contendo o termo } t} \right)$$

$$IDF(t, D) = \log \left(\frac{N}{df} \right)$$

$$IDF("gato") = \log \left(\frac{3}{2} \right)$$

$$IDF("gato") = \log(1,5)$$

$$IDF("gato") \approx \mathbf{0,405}$$



CÁLCULO FINAL DA TF-IDF PARA PALAVRA “GATO”

- Agora, multiplicamos os valores obtidos $TF \times IDF$

– Para D_1

$$\text{➤ } TF - IDF = 0,2 \times 0,405 = \mathbf{0,081}$$

– Para D_2

$$\text{➤ } TF - IDF = 0,2 \times 0,405 = \mathbf{0,081}$$

– Para D_3

$$\text{➤ } TF - IDF = 0 \times 0,405 = \mathbf{0,0}$$



COMO FICARIA PARA A PALAVRA "PEIXE"?

$$TF("peixe", D_1) = \frac{1}{5} = \mathbf{0,2}$$

$$IDF("peixe") = \log\left(\frac{3}{1}\right) = \log(3) \approx \mathbf{1,098}$$

$$TF - IDF("peixe", D_1) = 0,2 \times 1,098 = \mathbf{0,219}$$

- O valor do "**peixe**" (**0,219**) é muito maior que o do "**gato**" (**0,081**) no primeiro documento.
- Isso acontece porque "**gato**" **aparece em mais documentos**, tornando-se uma **palavra "comum"** e, portanto, menos importante para caracterizar o que o Documento 1 tem de único.

IMPLEMENTAÇÃO EM PYTHON

Usando scikit-Learn e Pandas

OBSERVAÇÕES IMPORTANTES

- Vamos usar as bibliotecas **scikit-learn** e **pandas**
 - A scikit-learn faz uma normalização nos valores das métricas de forma que para cada palavra no documento varie de 0 à 1. Isso é feito para que documentos longos não tenham valores desproporcionalmente maiores que documentos curtos.
 - Também há uma suavização no calculo da IDF, chamando de **Smooth IDF**. Serve para que palavras que aparecem em todos os documentos não tenham peso zero, evitando erros matemáticos em modelos de classificação:

$$IDF(t, D) = \log \left(\frac{1 + N}{1 + df} \right) + 1$$

IMPORTAÇÃO DAS BIBLIOTECAS E DEFINIÇÃO DO CORPUS



```
1 from sklearn.feature_extraction.text import TfidfVectorizer
2 import pandas as pd
3
4 # 1. Definimos os documentos (o nosso corpus)
5 corpus = [
6     "O gato comeu o peixe",
7     "O gato dormiu no sofá",
8     "O cachorro correu no parque"
9 ]
```



CÁLCULO DAS MÉTRICAS E COMPILAÇÃO DO VETOR DE VALORES



```
11 # 2. Inicializamos o Vectorizer
12 # O parâmetro stop_words pode ser usado para ignorar
13 # palavras como "o", "no", etc.
14 vectorizer = TfidfVectorizer()
15
16 # 3. Ajustamos e transformamos os dados
17 tfidf_matrix = vectorizer.fit_transform(corpus)
```



MONTAGEM DO DATA FRAME DE VISUALIZAÇÃO DOS DADOS

```
19 # 4. Transformamos em um DataFrame para facilitar a visualização
20 df_tfidf = pd.DataFrame(
21     tfidf_matrix.toarray(),
22     columns=vectorizer.get_feature_names_out(),
23     index=['Documento 1', 'Documento 2', 'Documento 3']
24 )
25
26 print(df_tfidf)
```



ANÁLISE DA MÉTRICA TF-IDF POR DOCUMENTO

	cachorro	comeu	correu	dormiu	gato	no	parque	peixe	sofá
Documento 1	0.000000	0.622766	0.000000	0.000000	0.473630	0.000000	0.000000	0.622766	0.000000
Documento 2	0.000000	0.000000	0.000000	0.562829	0.428046	0.428046	0.000000	0.000000	0.562829
Documento 3	0.528635	0.000000	0.528635	0.000000	0.000000	0.402040	0.528635	0.000000	0.000000

POR QUE USAR TF-IDF?

- Destaque de palavras-chave: Ele identifica o que é único em um texto. Se você tem um artigo sobre "Aprendizado de Máquina", palavras como "gradiente" ou "regressão" terão um peso alto, enquanto "artigo" terá um peso baixo.
- Redução de ruído: Naturalmente "pune" as stop words (artigos, preposições) sem a necessidade de uma lista exaustiva de exclusão, já que elas aparecem em quase todos os documentos (IDF baixo).
- Simplicidade e Eficiência: É um método matematicamente simples, mas extremamente poderoso para transformar texto em vetores numéricos que modelos de Machine Learning conseguem entender.

EXERCÍCIOS

Aplicações das métricas TF-IDF

EXERCÍCIO 1

- Considere o seguinte conjunto de documentos:
 - doc1 = "o gato dorme no sofá"
 - doc2 = "o cachorro dorme no tapete"
 - doc3 = "o gato caça o rato"
 - doc4 = "o cachorro corre no parque"
- Utilizando **TF-IDF**, faça o seguinte:
 - a) Crie uma lista com os documentos.
 - b) Utilize **TfidfVectorizer** para transformar os textos em uma **matriz TF-IDF**.
 - c) Exiba: a matriz resultante e as palavras (features) extraídas do corpus
 - d) Identifique manualmente quais palavras possuem maior peso em cada documento
 - e) Explique por que palavras como "o" possuem peso baixo.



EXERCÍCIO 2

- Considere os documentos abaixo sobre tecnologia:
 - doc1 = "python é muito usado para ciência de dados"
 - doc2 = "java é muito usado no desenvolvimento corporativo"
 - doc3 = "python é popular em machine learning"
 - doc4 = "javascript é usado no desenvolvimento web"
- Tarefas:
 - a) Gere a matriz TF-IDF.
 - b) Para cada documento, encontre: as 3 palavras com maior peso TF-IDF.



EXERCÍCIO 3

- Considere o conjunto de frases:
 - doc1 = "o banco aprovou o empréstimo do cliente"
 - doc2 = "o cliente solicitou um empréstimo no banco"
 - doc3 = "o jogador marcou um gol no campeonato"
 - doc4 = "o time venceu o campeonato de futebol"
- Tarefas:
 - a) Construa a matriz TF-IDF.
 - b) Calcule a similaridade de cosseno entre todos os documentos.
 - c) Identifique: quais documentos são mais semelhantes e quais são mais diferentes
- Discussão:
 - Por que os documentos sobre banco e empréstimo são mais similares entre si do que com os documentos sobre futebol?



EXERCÍCIO 4

- Considere o seguinte conjunto de documentos:
 - doc1 = "machine learning é usado para previsão de vendas"
 - doc2 = "redes neurais são usadas em reconhecimento de imagem"
 - doc3 = "análise de dados ajuda empresas a tomar decisões"
 - doc4 = "algoritmos de aprendizado de máquina analisam grandes volumes de dados"
- Agora considere a consulta do usuário:
 - query = "aprendizado de máquina e dados"
- Tarefas:
 - a) Treine um vetor TF-IDF com os documentos.
 - b) Transforme a consulta em vetor TF-IDF.
 - c) Calcule a similaridade entre a consulta e cada documento.
 - d) Exiba os documentos ordenados do mais relevante para o menos relevante.

EXERCÍCIO 5

- Considere os seguintes textos:
 - doc1 = "o governo anunciou novas medidas econômicas"
 - doc2 = "a bolsa de valores registrou alta no mercado financeiro"
 - doc3 = "o time venceu o campeonato nacional de futebol"
 - doc4 = "o treinador convocou novos jogadores para a seleção"
 - doc5 = "o banco central alterou a taxa de juros"
- Tarefas:
 - a) Gere a matriz TF-IDF.
 - b) Agrupe os documentos por semelhança semântica observando: quais documentos pertencem ao tema economia e quais pertencem ao tema esporte
 - c) Liste as palavras mais importantes em cada grupo.
- Pergunta:
 - O TF-IDF consegue separar automaticamente economia de esporte? Por quê?



OBRIGADO!

- Encontre este **material on-line** em:
 - Slides: **Google Classroom**
- Em caso de **dúvidas**, entre em contato:
 - **Prof. Me. Tiago:** tiago.silva@cps.sp.gov.br

