



WORD EMBEDDINGS

PROCESSAMENTO DE LINGUAGEM NATURAL
CST em Desenvolvimento de Software Multiplataforma



PROF. Me. TIAGO A. SILVA



O QUE SÃO WORD EMBEDDINGS

- São uma evolução natural após técnicas como **Bag of Words** e **TF-IDF**.
- A ideia central é **representar palavras como vetores densos em um espaço vetorial**, onde palavras com significados semelhantes ficam próximas.
- Isso permite capturar relações semânticas que métodos anteriores não capturam.



RELEMBRANDO O PROBLEMA DO BAG OF WORDS

- Considere as frases:

- O gato bebe leite
- O cachorro bebe leite
- O gato caça rato

No Bag of Words, cada palavra vira uma dimensão:

PALAVRA	VETOR
gato	[1, 0, 1]
cachorro	[0, 1, 0]
bebe	[1, 1, 0]

- O problema:

- **Vetores são esparsos** e não existe noção de significado

MAS O QUE SÃO VETORES DENSOS?

- Para entender espaço vetorial denso, precisamos primeiro separar os três conceitos:

1) Vetor

2) Espaço Vetorial

3) Densidade da Representação



1. DEFINIÇÃO DE VETOR

- Um vetor é simplesmente uma lista ordenada de números.

$$v = [0.2, -1.3, 0.8, 2.1]$$

- Podemos imaginar isso como **um ponto em um espaço matemático**:
 - **2 números** sendo um ponto em um plano (**2D**)
 - **3 números** sendo um ponto no espaço (**3D**)
 - **300 números** sendo ponto em um espaço de **300 dimensões**

2. O QUE É UM ESPAÇO VETORIAL?

- Um espaço vetorial é o conjunto de todos os **vetores possíveis de uma dimensão específica.**
- Vamos tomar como base um espaço vetorial 3D:

$$[x, y, z]$$

- Então qualquer ponto ficaria sendo:

$$[1, 2, 3], [5, 8, -1], [0, 0, 0]$$



3. DE ONDE VEM O DENSO?

- Uma representação **densa** significa que:
 - A maioria das posições do vetor tem valores diferentes de zero.

$[0.13, -0.72, 0.55, 0.91, -0.04]$

- Diferente dos vetores com **representação esparsa**: Bag Of Words:

$[0, 1, 0, 0, 1]$



O USO DE VETORES DENSOS EM WORD EMBEDDINGS

- A ideia é poder “somar” ou “subtrair” palavras, possibilitando um **sentido semântico**, algo como


$$rei - homem + mulher \approx rainha$$

- Isso funciona porque os vetores vivem em um espaço vetorial contínuo onde relações semânticas viram relações geométricas.

ESPAÇO VETORIAL SEMÂNTICO

- Faça a analogia: imagine que cada palavra tem coordenadas em um mapa de significado:

– rei	(0.21, 0.88)
– rainha	(0.24, 0.91)
– homem	(0.19, 0.70)
– mulher	(0.22, 0.74)
– gato	(-0.55, 0.12)



$$rei - homem + mulher \approx rainha$$

ENTÃO, JUNTANDO OS CONCEITOS

- Espaço vetorial denso é um espaço matemático onde cada palavra é representada por um vetor de números reais, no qual a maioria das dimensões possui valores diferentes de zero, permitindo capturar relações semânticas entre palavras.



ENTÃO, JUNTANDO OS CONCEITOS

- Se temos um vocabulário:

$$V = \{w_1, w_2, \dots w_n\}$$

- Um embedding é uma função:

$$f : V \rightarrow R^d$$

- Onde:

- V é o conjunto de palavras (vocabulário)
- d é a dimensão do vetor (2D, 3D, ND)
- R^d é o espaço vetorial da dimensão d

- Ou seja:

$$f(rei) = [0.21, 0.88]$$



O QUE SÃO EMBEDDINGS?

- A palavra “embedding” vem da matemática: **embedding é o ato de mapear objetos discretos para pontos em um espaço vetorial contínuo.**
 - Como acabamos de ver no slide anterior.
 - Considere as palavras:

PALAVRA	VETOR DENSO
gato	[0.21, -0.33, 0.78, 0.10]
cachorro	[0.25, -0.30, 0.74, 0.08]
carro	[-0.60, 0.71, -0.12, 0.55]
ônibus	[-0.58, 0.68, -0.15, 0.59]

gato e cachorro são vetores parecidos, assim como **carro e ônibus**

RESOLVENDO O PROBLEMA

- Um embedding transforma cada palavra em um vetor denso de dimensão pequena. Exemplo (dimensão = 3):

PALAVRA	VETOR
gato	[0.2, 0.7, 0.1]
cachorro	[0.25, 0.65, 0.15]
leite	[0.9, 0.1, 0.2]

- Agora podemos medir similaridade semântica usando **similaridade do cosseno**.
 - A fórmula matemática é dada pelo **produto escalar dos vetores dividido pelo produto de suas normas**.

A SIMILARIDADE DO COSSENO

- Para medir o quão próximas duas palavras estão, usamos a Similaridade de Cosseno. Diferente da distância euclidiana, **ela foca no ângulo entre os vetores**.
- Considere os vetores anteriores para as palavras *gato* e *cachorro*

$$\text{similaridade} = \cos(\theta) = \frac{\text{gato} \cdot \text{cachorro}}{\|\text{gato}\| \|\text{cachorro}\|} = \frac{\sum_{i=1}^n \text{gato}_i \text{cachorro}_i}{\sqrt{\sum_i^n \text{gato}_i^2 \sum_i^n \text{cachorro}_i^2}}$$

- Onde se *similaridade* for:
 - **1.0**: Palavras idênticas ou sinônimos perfeitos.
 - **0.0**: Palavras sem relação.
 - **-1.0**: Significados opostos (raro em embeddings comuns).

QUAL O NÚMERO IDEAL DE DIMENSÕES?

MODELO	DIMENSÃO
Pequenos	50
Médios	100–300
Grandes	768
LLMs	1024–4096

- Bibliotecas prontas:
 - **Word2Vec**: 300 dimensões
 - **GloVe**: de 50 à 300 dimensões
 - **BERT**: 768 dimensões



EXEMPLO EM PYTHON

```
1  # %pip install gensim
2  from gensim.models import Word2Vec
3
4  sentences = [
5      ["gato", "come", "peixe"],
6      ["cachorro", "come", "carne"],
7      ["gato", "e", "cachorro", "sao", "animais"]
8  ]
9
10 # Treinando o modelo
11 # vector_size: tamanho do vetor (embedding)
12 # window: janela de contexto
13 # min_count: ignora palavras que aparecem menos que X vezes
14 model = Word2Vec(sentences, vector_size=5, window=2, min_count=1)
15
16 print(model.wv["gato"])
```



EXERCÍCIOS

Word Embeddings usando Python

EXERCÍCIOS

- 1) Dada uma lista de frases (corpus), utilize o `word2vec` do `gensim` para treinar um modelo com uma dimensão de vetor (`vector_size`) igual a 100 e uma janela (`window`) de 5.
- 2) Use o modelo treinado no Exercício 1 (ou um modelo pré-treinado) para encontrar as 3 palavras mais similares à palavra "linguagem".



```
1  sentencas = [  
2      ["o", "processamento", "de", "linguagem", "natural", "e", "incrível"],  
3      ["aprendizado", "de", "maquina", "e", "uma", "subarea", "da", "ia"],  
4      ["redes", "neurais", "sao", "usadas", "em", "deep", "learning"],  
5      ["o", "gensim", "e", "excelente", "para", "word", "embeddings"]  
6  ]
```

OBRIGADO!

- Encontre este **material on-line** em:
 - Slides: **Google Classroom**
- Em caso de **dúvidas**, entre em contato:
 - **Prof. Me. Tiago:** tiago.silva@cps.sp.gov.br

